

東 北 大 學

信息科学与工程学院
硕士研究生学位论文中期报告

学 号： 1870603

姓 名： 李星扬

导 师： 徐建有

学科类别： ☐工学 ☒全日制专业学位

学科/工程领域： 控制工程

研究方向： 基于机器学习的实验电机轴承
故障诊断方法研究

论文题目： 基于机器学习的实验电机轴承
故障诊断方法研究

完成学分： 22

东北大学研究生院
2020 年 7 月 19 日

排版格式

一、中期检查报告首页各项按要求填写。

二、除原有标题外，中期检查报告正文部分使用非加粗宋体、小四号字；
如需设置小标题，使用加粗宋体、小四号字。

三、段落首行缩进 2 字符。

四、撰写时，将各部分标题下括号中的说明文字删除。

五、如需打印，请 A4 纸正反面打印。

一、论文工作总体完成情况

1. 开题报告中的论文主要研究内容

在选题开题阶段，由上海宝信软件公司工信部 2017 年工业转型升级“中国制造 2025”重点项目为依托背景，初定研究方向为 AR 技术在钢铁企业故障诊断系统中的应用，在导师的指导下围绕 AR 技术、钢铁生产设备的故障诊断两个课题关键词展开了理论研究和实验分析。

钢铁工业作为国民经济的基础原材料产业，在在促进经济发展方面扮演着重要角色。钢铁发展直接影响着与其相关的国防工业及建筑、机械、造船、汽车、家电等行业。虽然我国粗钢产量十多年中一直处于世界领先水平，但是技术落后、组织结构不合理等多种问题依然存在。钢铁企业如何在激烈的市场竞争中立足，全面提高生产线质量、设备的维修维护、保障设备的稳定运行十分必要。本课题研究旨在搭建基于深度学习的设备故障诊断神经网络模型，实现对车间设备历史故障及正常数据的特征进行深层次的提取和挖掘，训练出具有快速收敛性、高准确率的故障诊断模型，能够对传感器采集到的实时数据精准判断出设备发生何种故障，且基于先进的 AR 技术将设备运行状态生动展示给诊断人员，将各机器的实时数据通过移动终端设备，传送到诊断人员处，方便在必要时随时观测系统运行状态并在设备出现故障时及时检修，构建一套完整的集设备故障诊断和故障解决方案于一体的先进的设备状态管理系统。

1.1 理论学习

1) 故障诊断方面的研究

全球学者针对先进故障诊断方法曾进行了大量的研究，并提出很多经典可靠的故障诊断方法。这些方法可以分为基于数学模型的故障诊断方法、基于经验知识的故障诊断方法和基于数据驱动的故障诊断方法三类。如下图给出了详细的故障诊断方法分类。

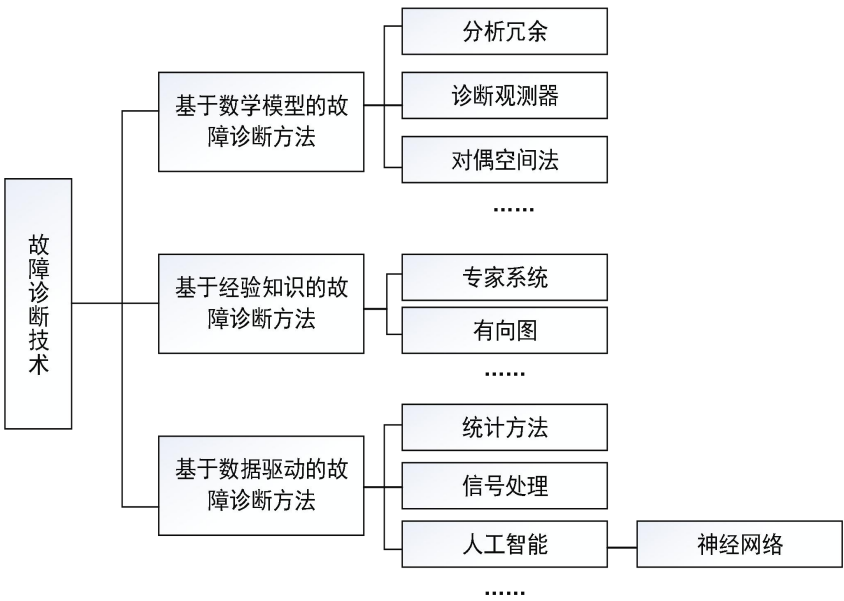


图1.1故障诊断方法分类

其中，以智能技术、自动化技术为核心的人工智能诊断故障方法，相比于传统的故障诊断方法效率更高、精确程度更强，能够对钢铁冶炼机械设备的故障实

现自动化、智能化诊断，目前已经是故障诊断方法中最为重要的一种，有着良好的发展前景。且人工智能故障诊断方法以人工神经网络预测体系为基础，同时融合了模糊数学理论，因此，与钢铁冶炼机械设备操作系统特别相适应。同时，该故障诊断方法设置了神经网络预测诊断系统、模糊逻辑智能诊断反映系统以及故障诊断管理系统等等。人工智能是科学研究领域非常重视的一个部分，因此，该方法还有巨大的提升空间。

2) AR技术的研究现状以及AR在设备故障诊断方面的应用情况

增强现实（Augmented Reality，AR）也称为混合现实，是指利用计算机技术，将虚拟的物体实时地叠加到一个真实画面或空间，形成具有实时交互的三维图像画面，给用户带来更真实的体验与感受。

移动AR技术是AR的一个分支。目前主要有传统移动AR技术和基于移动终端的移动AR技术两种。传统移动AR技术主要依靠PC机、头盔显示器或者全球定位系统（GPS）、磁传感器等一些外接设备来完成系统。该类系统具有设备昂贵，不便于长期携带，维护成本较高等局限性。而基于移动终端的移动AR技术近几年发展迅速，已经被应用在教育娱乐、建筑工程、地理导航和医疗生活的多个方面。移动AR技术最重要的特征是移动，它的应用场景更加广大，不仅仅只是局限在桌面上。因此移动AR技术将会是未来发展的主流趋势，尤其是基于移动终端的移动AR技术。

关于AR技术在设备故障识别方面的应用，它可以融合更多的传感技术，可以让设备运行状态信息一目了然，在电气和机械设备内部发热的早期可被发现，快速查找故障点。AR技术可以说是热成像技术的加强版，使用AR技术建模的智慧工厂建筑内部情况也可以随时掌控。如德国宝马公司专门开发出了一款增强现实眼镜，宝马汽车维修人员戴着眼镜就可以看到高亮显示的零件，计算机告诉使用者按照何种顺序如何安装。技师佩戴的眼镜上的小型屏幕让技师可以在真实环境下看到计算机生成的图片。同样还有钢铁行业的案例，富士通公司，为了改善工厂设备维修维护工作人员的现场作业环境，该公司已经将增强现实技术应用于自身的设备点检与24×7的服务运营中。

3) 虚拟现实的开发工具与技术

a) 三维建模技术

目前，主流游戏引擎由于其功能之强大，被用于诸多AR/VR产品的三维建模开发，其中3D引擎的使用更为广泛，常用的3D引擎有：Unity、Unreal Engine 虚幻引擎、Quest3D、VRP、EON等。主攻学习Unity3D引擎的使用，尝试使用Unity3D建立坦克大战小游戏。

b) 人机交互技术

较为常用的交互技术主要有手势识别、面部表情的识别、眼动跟踪以及语音识别等。

c) AR跟踪注册技术

跟踪注册技术的主要目的是保证虚拟信息能够实时准确地叠加到场景上。注册即为将虚拟信息与摄像机获得的真实场景进行配准的过程。而要实现虚拟信息在真实场景中的精确注册则需要从当前场景中获取虚拟信息与摄像机之间的位置关系，这要求AR系统必须实时地检测摄像机在真实场景中的位置和方向，这个过程称为跟踪。跟踪注册的实质就是确定虚拟物体坐标系与真实世界坐标系、真实世界坐标系与摄像机坐标系、摄像机坐标系与图像坐标系的转换关系，从而计算出虚拟信息在图像坐标系中的位置。常用的跟踪注册技术有基于传感器的跟

踪注册技术和基于计算机是觉得跟踪注册技术。

1.2 研究内容

1.2.1 研究方案

在课题理论学习的基础上，设计了研究方案，将课题分为两个主要部分：

1) 搭建基于深度学习的设备故障诊断神经网络模型

实现对车间设备历史故障及正常数据的特征进行深层次的提取和挖掘，训练出具有快速收敛性、高准确率故障诊断模型，能够对传感器采集到的实时数据精准判断出设备发生何种故障；

2) 检测系统基于AR技术的移动终端现实

实现检测系统在移动终端的支持下展示，仿真运行过程中检测人员和决策人员不仅能得到各种重要的检测数据，而且可以看到相应的三维仿真动画，并直观地看到检测结果，从而提供了系统运行的直观性和逼真性，有助于他们理解和认识所研究系统的本质和动态规律；

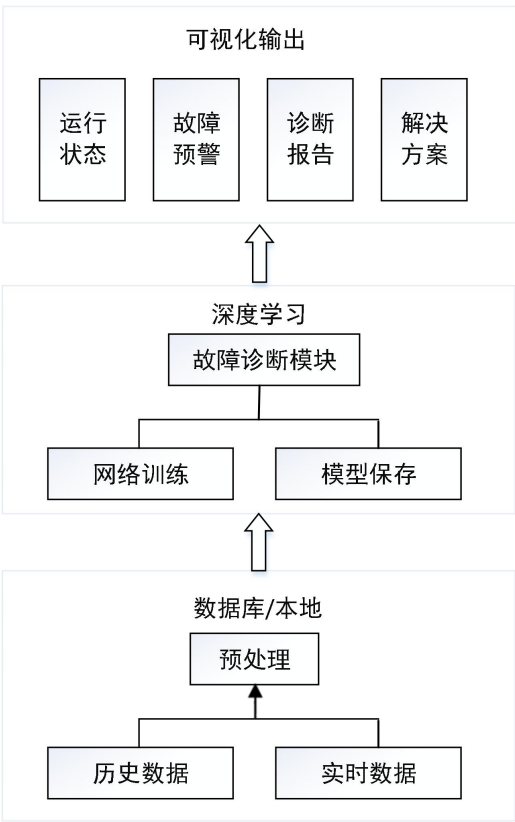


图1.2 系统架构示意图

1.2.2研究内容

1) 设备故障诊断神经网络模型的搭建

故障树是一种特殊的倒立状逻辑关系因果图，它用事件符号、逻辑口符号和转移符号描述系统中各种事件之间的因果关系。在系统设计和运行的过程中通过对可能造成系统失效的各种因素（包括硬件、软件、环境、人为因素）进行分析，画出故障逻辑关系图（失效树），从而确定系统失效的各种可能的原因和各种可能的组合方式或发生概率，进而采取相应措施提高系统可靠性的一种设计分析方法。




图 1.3 故障树的建立步骤

知识库是系统的核心之一，存放系统求解问题所需要的专家知识。整个知识库包括故障解决方案和故障原因。知识库中需要事先罗列出该设备或零部件所有可能发生的故障，导致某种故障所有可能的原因以及相应的解决方案。目前,应用较多的知识获取方式是知识的间接获取方式,也是比较成熟的方式,其过程是首先领域专家将自己的知识用语言及书面的形式整理出来然后,知识工程师在领域专家的帮助下对知识进行分析、抽取及简化,形成易于计算机理解的知识表达形式。对于知识库中的知识的表示应满足三个基本要求:

- a) 表示方案应便于知识的修改和扩充;
- b) 表示方案应尽量简单易懂;
- c) 表示方法应该清晰明确。

当我们得知设备发生某种故障时，将该故障类型输入到知识库中，知识库将根据索引给出相应的故障类型和故障解决方案，大大节省了维护人员的时间。

基于卷积神经网络的设备故障诊断技术研究

搭建故障诊断神经网络模型。通过深度学习技术对历史数据进行训练，不断地优化神经网络的结构，调节网络的超参数，使神经网络拥有更快的收敛速度和更高的准确率。卷积神经网络是多级神经网络，包含滤波级与分类级。其中，滤波级用来提取输入信号的特征，分类级对学习到的特征进行分类，两级网络参数是共同训练得到的。滤波级包含卷积层，池化层与激活层等3个基本单元，而分类级一般由全连接层组成。本系统主要是对一维的故障信息进行分析处理，所以神经网络模型为一维的卷积神经网络结构。

2) 基于 AR 的移动终端的故障诊断结果展示

a) 跟踪注册技术的研究与实现

跟踪注册技术是增强现实系统的基础,其主要目的是保证虚拟信息能够实时准确地叠加到场景上。注册即为将虚拟信息与摄像机获得的真实场景进行配准的过程。而要实现虚拟信息在真实场景中的精确注册则需要从当前场景中获取虚拟信息与摄像机之间的位置关系,这要求 AR 系统必须实时地检测摄像机在真实场景中的位置和方向,这个过程称为跟踪。跟踪注册的实质就是确定虚拟物体坐标系与真实世界坐标系、真实世界坐标系与摄像机坐标系、摄像机坐标系与图像坐标系的转换关系,从而计算出虚拟信息在图像坐标系中的位置。

本课题拟采用基于机器视觉的跟踪注册技术,包括基于人工标识的跟踪注册和基于自然特征的跟踪注册方法。基于人工标记的跟踪注册方法在图像识别时需要采用图像的阈值分割,根据像素的灰度特性识别出标记物;而基于自然特征的跟踪注册算法通过识别物体的几何特征来实现跟踪注册。

b) 系统显示技术的研究与实现

视觉是人类与外界环境之间最为重要且直接的信息传递通道,因此,显示技术是增强现实技术中的关键技术之一。显示技术的作用是将计算机生成的虚拟信息与用户所处真实环境融合在一起。AR 系统中的显示技术有头戴式显示器(HMD)和移动终端、投影显示器等。移动终端的硬件能力不断提升,其便携性和

低成本的特点使其被广泛应用。本课题拟采用头戴式显示器和移动终端来完成系统显示技术的实现。

c) 智能交互技术的研究与实现

在增强现实系统中，有多种方式实现人机交互，从传统的鼠标键盘交互到语言、手势交互，人机交互技术的发展将极大的扩展增强现实技术的应用。常见的人机交互方式有以下几种：1) 基于传统的硬件设备，如鼠标、键盘、手柄等；2) 手势交互手段，通过提取人手的三维坐标、手势来操作交互界面上显示的三维虚拟物体或者场景。3) 便携式投影互动技术。本课题拟采用手势交互技术，采用计算机视觉和深度学习的方法来完成智能交互的实现。

1.2.3拟采取的技术路线、实施方案

课题研究方案的技术路线如图所示，首先查阅相关文献，确定研究内容分为以下几个部分：设备故障树的建立，解决方案知识库的建立，数据预处理，故障诊断卷积神经网络系统的搭建，跟踪注册技术的实现，系统展示的实现，人机交互的实现。

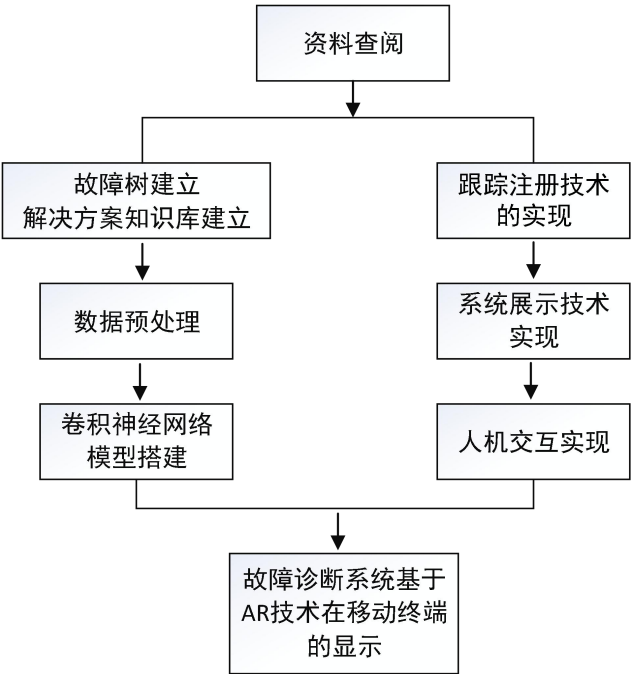


图 1.4 技术路线及实施方案

2. 论文主要研究内容调整情况

2.1 研究目标与研究方案调整

开题的研究内容是基于移动终端和 AR 技术的加热炉设备故障诊断，主要研究目标是通过设备故障诊断神经网络模型，实现对车间设备历史故障及正常数据的特征进行深层次的提取和挖掘，训练出具有快速收敛性、高准确率故障诊断模型，在此基础上，将近年来先进的 AR 技术应用到加热炉的数据显示和状态检测中，将设备运行状态通过移动终端设备，传送到诊断人员处。由于预期研究问题所需数据采集难度大、且部分现场数据存在缺失等实际原因，加之课题组研究方向变更，为了更好的完成课题组科研任务，因此研究目标进行变更为项目组更为迫切需求的基于机器学习的故障诊断方法研究。该研究同样对实际生产有较强

的指导意义，且本课题使用来自于凯斯西储大学（CWRU）滚动轴承数据中心的 C 数据集，这是世界公认的轴承故障诊断标准数据集，有较强的认可度。同时题目变更为：基于机器学习的实验电机轴承故障诊断方法研究。主要研究内容是搭建基于深度学习的设备故障诊断神经网络模型，实现对轴承正常数据的特征进行深层次的提取和挖掘以及故障类型区分，能够对传感器采集到的实时数据精准判断出设备发生何种故障，训练出具有快速收敛性、高准确率故障诊断模型。

2.2 国内外研究现状

2.2.1 国内研究现状

近两年，国内在轴承智能故障诊断领域，特别是利用数据驱动的特征提取技术进行故障诊断，处于世界领先地位。国内多所大学开展了该研究。

2015 年，清华大学的王学谦等利用堆叠式的稀疏自编码器构建深度神经网络，对滚动轴承进行故障诊断。该网络采用逐层训练的方式，前一层作为一个稀疏自编码器的输入层，后一层作为其隐含层，由下往上逐层训练，最后再使用有监督学习进行网络参数微调。为了达到降噪的目的，作者先对时域的振动信号采用了小波变换。作者对美国凯斯西储大学 CWR（Case Western Reserve University）轴承数据库进行诊断，结果表明该方法优于传统的 BP 网络。

2016 年，中国科技大学的竺长安等人利用深度置信网络，提出使用分层诊断网络 HDN（Hierarchical Diagnosis Network），对滚动轴承进行故障诊断。该方法先使用 DBN 确定轴承损伤位置，即无缺陷，内圈，外圈与滚动体缺陷的诊断，再用 DBN 对损伤的大小进行诊断，诊断的结果一共 10 类。利用该分层结构，对采样频率为 12kHz 的 CWRU 的轴承数据进行分类，在 BPNN 与 SVM 分别达到 95.14%与 96.48%的基础上，DBN 达到了 99.03%的诊断正确率。

2019 年，金余丰等针对轴承故障诊断过程中存在的特征提取复杂、分类器训练困难等问题，提出了一种基于残差网络和注意力机制相结合的滚动轴承故障诊断模型。该模型以滚动轴承的一维振动时序信号作为输入，通过残差网络完成特征提取，然后经带有注意力机制的双向长短记忆神经网络单元，实现特征在时序上的表达并赋予不同的权重，输出到分类器完成端到端的振动信号分类，完成滚动轴承故障的诊断。该模型的诊断准确率可达 99.86%以上，对各故障类别的诊断率均在 99%以上，提取的特征信息区分度高；模型诊断准确率优于基于特征工程的诊断模型、稳定性优于其他基于深度学习的诊断模型。

2020 年，咎涛等针对滚动轴承信号易受噪声干扰和智能诊断模型鲁棒性差的问题，在一维卷积网络的基础上，提出基于多输入层卷积神经网络的滚动轴承故障诊断模型。该模型具有多个输入层，初始输入层为原始信号，以最大化地发挥卷积网络自动学习原始信号特征的优势；同时可将谱分析数据在模型任意位置输入模型，以提升模型的识别精度和抗干扰能力。结果表明，所提出的模型提升了人工神经网络(Artificial Neural Network,ANN)、支持向量机(Support Vector Machine,SVM)和典型的卷积神经模型等传统卷积模型的识别率和收敛性能，并具有较好的鲁棒性和泛化能力。

2.2.2 国外研究现状

2013 年，Nishchal 等人利用堆叠式稀疏自编码器（SAE，Stacked Sparse Auto-encoder）提取稀疏特征，对轴承以及阀门进行故障诊断。研究人员分别从时域，频域以及小波域提取了 87 个特征，再将这 87 个特征作为深度网络的输入，逐层训练稀疏自编码器。最后利用支持向量机对整个深度网络进行有监督微调，取得了 95.96%的诊断正确率。

2015 年, Jinane 等提出了一种新的特征提取方法, 即全局谱分析 (Global Spectrum Analysis), 来分析轴承振动信号。该方法首先使用包络检测与快速傅里叶变换进行信号预处理, 经过主频特征选择, 再通过主成分分析来提取主特征, 最后利用线性判别器进行分类。该方法的优点是不依赖先验知识, 并且可以获得很好的分类结果。

2016 年, 德国亚琛工业大学 Christelle 等提出使用电流信号来诊断轴承故障。该方法首先计算故障主频率, 再建立由标准差, 峰度, 偏度, 波峰因子, 间隙与形状因子等六个统计学参数构成的特征矩阵, 接着使用线性判别器进行特征降维, 最后利用贝叶斯分类器进行故障分类。该方法的优点是无需安装传感器就可以进行诊断, 缺点是在小负载的情况下, 几乎无法实现诊断。

2017 年, 美国伊利诺伊大学芝加哥分校的 David 等提出了大内存存储检索网络 LAMSTAR (large memory storage retrieval), 对轴承进行故障诊断。该网络由一个输入层, 多个输入自组织映射 SOM (self-organizing maps) 模块, 以及一个决策 SOM 模块构成。输入 SOM 模块隐含层, 用来提取特征, 决策 SOM 是输出层。作者首先对传感信号进行短时傅里叶变换, 获取传感信号的频谱图, 再用 LAMSTAR 进行分类。该算法在不同的转速下的诊断率均达到了 96% 以上。

2.3 研究内容

滚动轴承作为标准件, 被广泛应用在众多机械设备中, 也是机械设备中非常容易损坏的零部件。据统计, 在使用滚动轴承的旋转机械中, 大约有三成的机械故障都是由轴承引起的。轴承状态是否良好对机械设备工作性能有较大的影响。滚动轴承故障模式识别一直是机械故障研究的热点之一。

机械设备的故障诊断通常是在设备关键位置安装传感器来采集设备的振动信号, 通过对原始振动信号进行特征挖掘, 再连接分类器, 从而构建一套完整的故障诊断系统。但是, 原始的振动信号中除了蕴含着故障的特征信息, 同时也包含了大量的噪声数据, 这些噪声数据会对后续分析处理造成干扰。而特征提取的目的就是提取原始振动信号中与故障类别相关的数据去除无用的噪声数据。滚动轴承常见故障包括外圈故障、滚动体故障、保持架故障和内圈故障。

智能故障诊断算法的成功与否关键在于特征提取器和分类器的选取, 不同的方法本质上都在寻找一种最优的组合, 使最后的识别率最高。卷积神经网络具有“端到端”的特点, 即可以通过一个神经网络完成特征提取、特征降维与分类器分类这一整套过程。卷积神经网络的这个特点无疑弥补了当下故障诊断方式的不足, 为故障诊断提供了一种崭新的研究思路。

基于上述情况, 本课题提出基于卷积神经网络的轴承故障诊断方法, 使用数据来源于凯斯西储大学 (CWRU) 滚动轴承数据中心, 被诊断的轴承一共有 3 种缺陷位置, 分别是滚动体损伤, 外圈损伤与内圈损伤, 损伤直径的大小分别为包括 0.007inch, 0.014inch 和 0.021inch, 共计 9 种损伤状态。主要研究内容如下:

(1) 建立作用于时域信号的卷积神经网络模型

针对轴承故障信号的特点, 设计包含两个卷积层的卷积神经网络模型, 将原始的一维时域振动信号作为输入, 故障类别作为输出。该模型直接作用在原始的时域振动信号上, 层数少, 计算量小, 识别率高, 可塑性强, 作为后续研究基础。

(2) 优化卷积神经网络: 第一层宽卷积核深度卷积神经网络

借鉴当下的深度学习技术, 将第一层卷积核设置为宽卷积核对信号进行特征提取, 提取短时特征, 获取较大的感受野, 其余卷积层全部使用小卷积核以减少网络参数和运算次数。对建立的传统神经网络进行结构优化。

(3) 基于批量归一化算法优化

在卷积层和全连接层后面加上批量归一化层（BN 层），其作用是减少内部协变量转移，提高网络的训练效率，增强网络的泛化能力。主要操作步骤是将卷积层或全连接层的输入先减去所在 mini-batch 的均值，再除以其标准差，类似于一种标准化操作，因此可以加速训练。

3. 目前论文主要研究内容的总体完成情况

由于研究内容较开题期间有一定变化，因此研究进展与开题报告所定计划也有些许不同。本课题现有进展如下：

1、设计了包含两个卷积层两个池化层的卷积神经网络模型，将原始的一维时域振动信号作为输入，选取的是轴承负载 1hp 下 9 种故障振动信号及正常的振动信号，共 10 类。将数据集切分成，75%作为训练集和 25%作为测试集。测试可得识别率达 97%。

2、将第一层卷积核设置为宽卷积核对信号进行特征提取，获取较大的感受野，其余卷积层全部使用 3×1 小卷积核以减少网络参数和运算次数。在卷积层和全连接层后面加上批量归一化层（BN 层），其作用是减少内部协变量转移，提高网络的训练效率，增强网络的泛化能力。对选用数据进行测试，识别率提升到 100%。

二、论文具体研究进展与所取得的阶段性成果

1 数据收集与处理

本课题使用数据取自凯斯西储大学轴承数据中心网站，是知名滚动轴承故障数据数据集。该数据采集自如图所示 2 马力的信实电机的承载轴承，轴承型号为深沟球轴承 SKF6205。采用放电加工方法对测试轴承引入单点故障，分别在三个不同位置内滚道、滚动件(即球)和外滚道播种直径为 0.007 英寸至 0.040 英寸的故障共 10 类。在靠近电机轴承和远离电机轴承的位置测量加速度数据，记录电机负载为 0 到 3 马力(电机转速 1797 到 1720 转/分)时的振动数据，系统的采样频率为 12kHz。




图 2.1 基于实验电机的数据采集系统

本课题目前阶段选取的是 1 马力荷载下驱动端轴承 9 种故障振动信号及正常

的振动信号，共 10 类，样本的重叠率为 50%。将数据集切分成，75%作为训练集和 25%作为测试集。样本参数如下表所。

表 2.1：数据参数表

样本类型	样本长度	样本数目	样本标签
正常	1024	235	1000000000
内圈损伤 7in	1024	235	0100000000
内圈损伤 14in	1024	235	0010000000
内圈损伤 21in	1024	235	0001000000
滚动体损伤 7in	1024	235	0000100000
滚动体损伤 14in	1024	235	0000010000
滚动体损伤 21in	1024	235	0000001000
外圈损伤 7in	1024	235	0000000100
外圈损伤 14in	1024	235	0000000010
外圈损伤 21in	1024	235	0000000001

2 卷积神经网络的搭建

本课题的数据为一维数据，因此输入为一维信号。卷积神经网络是多级神经网络，包含滤波级（filtering stage）与分类级（classification stage）。其中，滤波级用来提取输入信号的特征，分类级对学习到的特征进行分类，两级网络参数是共同训练得到的。滤波级由卷积层(convolutional layers)，池化层(pooling layers)与激活层(activation layers)等 3 个基本单元组合而成，分类级包含全连接层。

2.1 卷积层

卷积层的目的是对输入的数据进行特征提取。通过卷积核有规律地扫过输入特征，在感受野内对输入特征做卷积运算，生成相应的特征图即特征提取。卷积层最重要的特点是权值共享，即同一个卷积核将以固定的步长遍历一次输入。权值共享可以大大地减少卷积层的网络参数，避免了由于参数过多造成的过拟合，并且降低了系统所需内存。其数学模型表示为：

$$x_j^l = f(\sum_{i \in M_j} x_i^{l-1} \times k_{ij}^l + b_j^l) \quad (2.1)$$

- 其中， x_j^l ——第 1 层的第 j 个输出特征；
- x_i^{l-1} ——第 l-1 层的第 i 个输入特征；
- k_{ij}^l ——第 l 层第 i 个卷积核的第 j 个权重；
- b_j^l ——第 l 层网络偏置；
- $f(\cdot)$ ——激活函数。

一维卷积层的运算过程如图 2.2 所示， x 表示第 1 层样本输入，图中图中一共有 i 个卷积核，每个卷积核均遍历一次输入层，与输入进行卷积运算。在进行卷积操作时，每个卷积核与被卷区域的神经元对应的系数相乘，再加上偏移量得到一个值 $y_{(i,b)}$ ，然后以一定步长移动卷积核，得到一个输出，重复之前的操作，直至卷积核遍历完输入信号的所有区域。

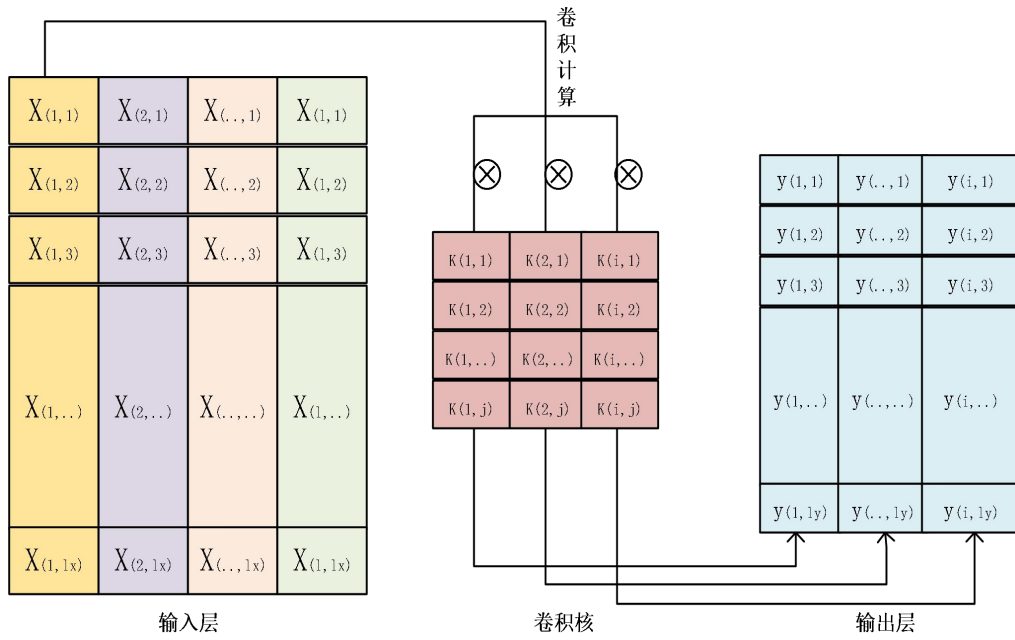


图 2.2 一维卷积层结构图

卷积层中包含激励函数以协助表达复杂特征,激励函数的作用是把卷积层输出结果做非线性映射,将原本线性不可分的多维特征映射到另一空间,在此空间内,特征的线性可分性将增强。卷积神经网络通常使用线性整流函数 (Rectified Linear Unit, ReLU), 以及 Sigmoid 函数和双曲正切函数 Tanh。三种激活函数的具体表达如式(2.2)、(2.3)与(2.4)所示:

$$a^{l(i,j)} = \text{Sigmoid}(y^{l(i,j)}) = \frac{1}{1 + e^{-y^{l(i,j)}}} \quad (2.2)$$

$$a^{l(i,j)} = \text{Tanh}(y^{l(i,j)}) = \frac{e^{y^{l(i,j)}} - e^{-y^{l(i,j)}}}{e^{y^{l(i,j)}} + e^{-y^{l(i,j)}}} \quad (2.3)$$

$$a^{l(i,j)} = f(y^{l(i,j)}) = \max\{0, y^{l(i,j)}\} \quad (2.4)$$

在本文中,将采用 ReLU 作为卷积神经网络的激活函数,避免梯度弥散现象。所谓梯度弥散现象,当梯度值为 1 时,梯度原封不动地反向传播。当梯度值为 0 时,从这点往后不会进行反向传播。当输入值的绝对值较大时, Sigmoid 与 Tanh 函数的导数值均接近 0,这会造成利用误差反向传播来更新权值时,随着神经网络层数的增加,误差值无法向下传播,从而底层网络训练不透,从而出现梯度弥散现象。当 $x > 0$ 时, ReLU 的梯度一直为 1,可以很好地克服这种现象。

2.2 池化层

本课题中采用的降采样操作为最大值池化。池化层 (Pooling Layer) 夹在连续的卷积层中间,进行的是降采样操作,用于压缩数据和参数的量,主要目的是减少神经网络的参数,减小过拟合。常用的池化函数有均值池化 (Average Pooling) 与最大值池化 (Max Pooling)。均值池化是将感知域的神经元的均值作为输出值,而最大值池化是将感知域中的最大值作为输出。采用最大值池化做的优点在于可以获得位置无关的特征,这一点对于周期性的时域信号很关键。如图 2.3 所示为一维池化操作示意图。

图中输入层的特征宽度为 i , 通过大小、步长均为 2 的池化操作,将原始特

征降采样到宽度为原来的一半的输出特征。




图 2.3 一维池化层操作示意图

2.3 全连接层

全连接层的任务是将滤波级提取出的特征进行分类。首先将最后一个池化层的输出，铺展成一维的特征向量，作为全连接层的输入；再将输入与输出之间通过激活函数进行全连接，其中隐含层使用的激活函数为 **ReLU**，最后输出层采用的是激活函数是 **Softmax** 函数。**Softmax** 函数的目的是将输入的神经元转化为和为 1 的概率分布，这样做有利于后续的多分类目标函数的建立。其数学表达式为：

$$z^{l+1(j)} = \sum_{i=1}^n W_{ij}^l a^{l(i)} + b_j^l \quad (2.5)$$

式中： W_{ij}^l ——第 l 层第 i 个神经元和第 l+1 层第 j 个神经元的权值；

$z^{l+1(j)}$ ——第 l+1 层第 j 个输出神经元的特征值；

b_j^l --第 l 层所有神经元对第 l+1 层第 j 个神经元的偏置值。

2.4 目标函数

本课题所设计卷积神经网络的目标函数（Objective Function）选用交叉熵损失（Cross-entropy Loss Function）函数。与平方误差函数（Squared Loss Function）比较每一个类别的大小不同，交叉熵函数是衡量两个概率分布的一致性。交叉熵函数在机器学习中常被看做是 softmax 分布的负对数似然，因此本文中将采用交叉熵函数。交叉熵函数为目标函数的数学表达式为：

$$L = -\frac{1}{m} \sum_{k=1}^m \sum_j p_k^j \log q_k^j \quad (2.6)$$

式中： m ——输入的小批量（mini-batch）的大小；

q ——卷积神经网络的实际输出的 **Softmax** 值；

$$p^j = \begin{cases} 1 & (\text{目标类别为 } j) \\ 0 & \end{cases}$$

2.5 用于实验电机的轴承诊断卷积神经网络模型

本课题提出的卷积神经网络的结构如图 2.4 所示。此卷积神经网络模型包含两个卷积层，两个池化层，一个全连接隐含层，以及一个 **Softmax** 层。诊断信号通过第一个卷积层以及 **ReLU** 激活层，变为一组特征图（Feature Maps），再经

过最大值池化进行降采样。重复一次以上操作，将最后一个池化层的特征图与全连接隐含层相连，经过 ReLU 激活之后，传递到最后的 softmax 层。




图 2.4 卷积神经网络的结构图

卷积神经网络的结构参数如表 2.2 所示，第一层卷积核大小为 10×1 ，步长为 4×1 ，第二层卷积核大小为 5×1 ，步长为 2×1 。第一个池化层的区域大小为 4×1 ，第二个池化区域大小为 2×1 。全连接层的神经元个数为 64。

表 2.2 一维卷积神经网络结构参数

网络层	卷积核大小/步长	卷积核数目	输出大小	补零
卷积层 1	$10 \times 1 / 4 \times 1$	32	256×32	是
池化层 1	$4 \times 1 / 4 \times 1$		64×32	否
卷积层 2	$5 \times 1 / 2 \times 1$	64	32×64	是
池化层 2	$2 \times 1 / 2 \times 1$		16×64	否
全连接	64		64×1	
softmax	10		10	

利用搭建好的网络对数据集进行训练。由于神经网络的初值是随机的，为了验证每次训练结果的可靠性，对于数据集，训练 20 次，综合结果，卷积神经网络在数据集上的平均识别率可达到 97%。由试验结果可知，卷积神经网络直接作用在时域的振动信号上，是可行的，并且可以取得很高的识别率。

2.3 优化卷积神经网络结构

上小节搭建出的卷积神经网络模型已经达到了很高的识别率，该模型验证了卷积神经网络直接作用在时域振动信号上的是可行的。由于该模型结构简单，可塑性很强，可以从多个角度进行改进。本课题研究如何减少网络参数个数，进而提高网络的诊断性能。

卷积神经网络的设计核心是感受野，即一个神经元在其下层网络中感知范围。常用的二维卷积神经网络均含有堆叠式的 3×3 的卷积核。这样既可以加深网络深度，也可以实现以较少的参数，获取较大的感受野，从而抑制过拟合。然而，对于一维振动信号，两层 3×1 卷积的结构，以 6 个权值为代价，仅仅获取了 5×1 的感受野，反而将上述优势变成了劣势，因此，针对一维原始振动信号的特点，可以将第一层卷积核设置为宽卷积核，对信号进行特征提取，获取较大的感受野。

由于振动信号是周期性的，且每一个输入信号的相位值不一定相同。为了让滤波级学习到位移无关的特征，最后一个池化层的神经元在输入信号中的感受野大小，应当大于一个周期。假设最后一个池化层的神经元在输入的感受野大小为 $R^{(l)}$ ， T 为轴承转动一圈，加速度计记录的数据点数， L 为输入信号长度，那么可以将 $T \leq R^{(l)} \leq L$ 作为卷积神经网络参数选择的准则。以下为设计过程。

首先求解最后一个池化层的神经元，在第 l 个池化层的感受野 R^l 与在第 $l-1$ 个池化层的感受野 $R^{(l-1)}$ 的关系，如式(2.7)所示：

$$R^{(l-1)} = S^{(l)}(R^{(l)}R^{(l)} - 1) + W^{(l)} \quad (2.7)$$

式中： $S^{(l)}$ 、 $W^{(l)}$ ——第 l 个卷积层的步长与卷积核宽度；

$P^{(l)}$ ——第 l 个池化层降采样点的个数。

选择 $S^{(1)}=1$ ， $W^{(1)}=3$ ， $P^{(1)}=2$ ，则：

$$R^{(l-1)} = 2R^{(l)} + 2 \quad (2.8)$$

又因为当 $l=n$ 时， $R^{(l)}=1$ ，其中 n 为卷积层个数。因此，最后一个池化层的神经元在第 l 个池化层的感受野大小如式(2.9)所示：

$$R^{(l)} = 2^{n+1} * 3 + 2 \quad (2.9)$$

经过整理，得到最后一个池化层的神经元在输入信号上的感受野的表达式如(2.10)所示：

$$R^{(l-1)} = S^{(l)}(R^{(l)}R^{(l)} - 1) + W^{(l)} = 2S^{(l)}2^{n+1} * 3 + 2 + W^{(l)} - S^{(l)} \approx S^{(l)}2^{n+1} * 3 - 4 \quad (2.10)$$

根据 $T \leq R^{(l)} \leq L$ 这一设计准则，加上 $S^{(l)}$ 必须能够整除 L 这一条件，可以得到最终的设计准则为：

$$T \leq S^{(1)}(2^n * 3 - 4) \leq L \quad (2.11)$$

以本文的输入信号为例，输入信号长度为 $L=1024$ ，信号周期 $T \approx 400$ ，如果有 5 层卷积层，那么第一层卷积层的卷积步长只能为 4 或者 8。在配置其他超参数时，需要注意，当增加卷积核的个数，宽度，以及网络的层数，或者减少卷积核的步长，网络的神经元的总数将会增加，这可以提高网络的表达能力，但也存在过拟合的风险。网络的其他超参数需要根据训练数据的多少，在试验中进一步调整。




图 2.5 优化卷积神经网络结构

第一层为大卷积核，目的是为了提取短时特征，其作用与短时傅里叶变换类

似。不同点在于，短时傅里叶变换的窗口函数是正弦函数，而第一层大卷积核，是通过优化算法训练得到，其优点是可以自动学习面向诊断的特征，而自动去除对诊断没有帮助的特征。其余卷积层使用小卷积核以减少网络参数，且可以加深网络，同时抑制过拟合。在卷积神经网络中的每层卷积操作后增加批量归一化层（简称 BN 算法），可以减少内部协变量转移，提高网络的训练效率，增强网络的泛化能力，本文在卷积操作之后和激活函数进行非变换之前添加 BN 层，实验证明 BN 层使网络的训练速度和准确率都有很大的提升。同时，将经典的卷积神经网络最后一层全连接层换成了全局均值池化层以减少网络参数数量。优化的卷积神经网络结构如图 2.5 所示。第一层卷积核大小为 32×1 ，步长为 4×1 ，第二层卷积核大小为 5×1 ，步长为 2×1 。第一个池化层的区域大小为 4×1 ，第二个池化区域大小为 2×1 。全连接层的神经元个数为 64。

表 2.3 宽卷积神经网络结构参数

网络层	卷积核大小/步长	卷积核数目	输出大小
卷积层 1	32x1/4x1	32	256x32
池化层 1	4x1/4x1	32	64x32
卷积层 2	3x1/1x1	64	64x64
池化层 2	2x1/2x1	64	32x64
卷积层 3	3x1/1x1	64	32x64
池化层 3	2x1/2x1	64	16x64
卷积层 4	3x1/1x1	64	16x64
池化层 4	2x1/2x1	64	8x64
全局均值池化层	64	1	64x1
softmax	10		10

基于 Tensorflow 环境测试所搭建的结构优化卷积神经网络模型，图 2.6 和图 2.7 分别是损失函数值和准确率，红色表示训练集，蓝色表示测试集。由图可看出经过宽卷积优化的神经网络测试准确率明显提升达到 99.83%。




图 2.6 测试集和训练集损失函数




图 2.7 测试集和训练集准确率

三、后续论文研究内容、研究计划与预期成果

1 后续论文研究内容与研究计划

虽然目前已经搭建的卷积神经网络已经在所选数据集上显示出较高的准确率，但是结构相对简单，其深度和结构仍然有改进的空间，尝试增大卷积神经网络的深度，优化结构以获得更高的准确率。除此之外，虽然宽卷积在一定程度上扩大了感受野，减少了网络参数，但是相对于多维卷积神经网络的多维卷积核起到的作用程度相对较低，考虑用空洞卷积的方法在宽卷积核结构上继续优化，减少网络参数，提高训练效率。

此外，在实际的工业应用中，工作环境十分复杂，由于工作任务的变化，机器工作负载也会随之改变，如何利用在一个负载下的数据进行训练，对另一个负载下的信号进行诊断，是衡量智能诊断算法适应能力的重要指标。如何提高网络的泛化性和自适应能力，也是后续主要研究内容之一。

2 预期成果

设计出直接作用在原始时域信号上，并且要达到高识别率的适用于轴承故障诊断的卷积神经网络。

(1) 通过宽卷积核和空洞卷积相结合的方法，减少一维卷积神经网络网络参数，加深网络深度，优化网络结构，达到搭建的卷积神经网络具有训练速度快且准确率高的目标。

(2) 寻找一种优化方法，在已搭建的神经网络模型具有较高故障类型识别准确率的前提下，提高模型的泛化性，用数据集中未使用的 2hp（马力）、3hp 负载数据进行测试，得到识别准确率高且适应性强的用于轴承故障诊断的卷积神经网络模型。

四、目前存在的问题与解决方法


本课题使用数据集来自实验电机，然而在实际的工业应用中，工作环境十分复杂，工业现场的噪声无法避免，使用加速度计测得的振动信号易被污染。如何使所搭建的卷积神经网络模型可以实际应用，适应实际工业现场的环境，具有良好的抗噪性能、较强的鲁棒性，是需要考虑的问题。

引入残差学习是图像去噪的常用方式，残差网络的特点是容易优化，并且能够通过增加相当的深度来提高准确率。本课题中在卷积神经网络模型中利用空洞卷积技术去扩大感受野，从而提取到更多的特征，后续可以通过残差学习加入跳跃连接，缓解在深度神经网络中增加深度带来的梯度消失问题，从而加快神经网络去噪模型的训练速度，同时可以提升重建后去噪算法的精度和收敛性。

五、导师意见

李星扬同学已经出色地完成了研究计划的相关内容。针对实验电机的轴承故障诊断研究问题，搭建了效果良好的卷积神经网络模型，并优化得到训练效果好、效率高的优化结构神经网络模型。实验结果表明，所提模型和算法有效。在论文工作期间，学习刻苦，团结同学，表现出很强的创新能力和实际工作能力。

导师签字：



2020 年 7 月 20 日